УДК 629.33:658.562:004.89:519.23

ПРОГНОЗИРОВАНИЕ ДЛИТЕЛЬНОСТИ РЕМОНТА В СЕРВИСНОЙ СЕТИ АВТОПРОИЗВОДИТЕЛЯ В УСЛОВИЯХ НЕПОЛНЫХ ДАННЫХ

И.П. Фрелих, В.Г. Мосин

Рассмотрена актуальная производственная задача оперативного прогнозирования длительности технического обслуживания и ремонта автотранспортных средств в дилерской сети автопроизводителя. Эффективное планирование загрузки сервисных постов и предоставление клиенту реалистичных сроков готовности автомобиля выступают ключевыми факторами лояльности автовладельцев и рентабельности сервисных станций. Исследован производственный массив из 50 000 заказ-нарядов официального сервисного центра, характеризующийся неполнотой информации: в 26,4% наблюдений отсутствуют сведения о времени предварительной диагностики. Показано, что механизм возникновения пропусков носит неслучайный характер (MNAR) и обусловлен технологическим регламентом: при кузовных дефектах мастер оценивает повреждения визуально без применения диагностических стендов, вследствие чего доля пропусков достигает 75,4%, тогда как по механическим агрегатам не превышает 10,0%. Проведено сравнительное исследование двух подходов к заполнению неполных данных: традиционной импутации средним значением и регрессионной импутации, восстанавливающей латентные связи между характеристиками автомобиля и длительностью диагностики. С целью устранения эффекта нестабильности одиночного разбиения валидация моделей выполнена на основе 100 независимых циклов случайного разделения выборки (80% обучение / 20% тест). Установлено, что регрессионная импутация обеспечивает устойчивый прирост коэффициента детерминации с $R^2 = 0{,}898$ до $R^2 = 0{,}923$ (+2,54 п.п.) и снижает среднюю абсолютную ошибку прогноза (MAE) до 0,65 ч (39 минут) против 0,76 ч (45 минут) при заполнении средним. С позиций предметной области доказано, что достигнутая точность модели позволяет формировать прозрачные клиентские обязательства с дискретностью «до одного часа» (регламентная формулировка «Приезжайте завтра после 14:00»), а также заблаговременно инициировать сценарии компенсационного сервиса (предоставление подменного автомобиля или сервисных сертификатов) при прогнозировании затяжных ремонтов.

Ключевые слова: техническое обслуживание и ремонт автомобилей, дилерская сервисная сеть, прогнозирование длительности ремонта, неполные данные, неслучайные пропуски, импутация пропусков, регрессионная модель, клиентский сервис, планирование сервисных постов, система менеджмента качества.

Введение

В современной индустрии сервисного обслуживания автомобилей повышение качества взаимодействия с клиентом и оптимизация операционной эффективности дилерских центров становятся ключевыми факторами конкурентоспособности автопроизводителя [1, 2]. Для автовладельца обращение в сервисный центр сопряжено с высокой неопределенностью: сдача автомобиля на станцию технического обслуживания (СТО) влечет временную потерю мобильности и необходимость перестройки личного графика. Традиционная практика приемки, при которой мастер-приемщик называет приблизительные или заведомо заниженные сроки («постараемся сделать к вечеру»), регулярно приводит к конфликтным ситуациям, срыву клиентских планов и падению индекса удовлетворенности потребителей (CSI) [3, 4].

С точки зрения начальника сервисного цеха и диспетчера постов, отсутствие надежной оценки трудоемкости ремонта нарушает ритмичность производственного процесса. Возникают либо простои подъемников и участков диагностики в ожидании завершения смежных операций, либо перегрузка цеха, ведущая к авральной работе персонала и сопутствующему росту технологического брака [5, 6].

В этих условиях критическую важность приобретает умение заблаговременно и достоверно прогнозировать продолжительность ремонта непосредственно в момент оформления заказ-наряда на посту приемки [7]. Наличие объективного прогноза позволяет:

– сообщить автовладельцу обоснованный срок выдачи автомобиля с точностью до конкретного часа рабочего дня;

– сформировать сбалансированный сменно-суточный график загрузки постов, слесарей и специнструмента;

– своевременно активировать программы поддержания клиентской лояльности (например, предложить клиенту бесплатную поездку на такси или подменный автомобиль при прогнозе затяжного ремонта свыше 6–8 часов).

Однако практическое внедрение математических методов прогнозирования в дилерских сетях сталкивается с фундаментальной инженерной проблемой — неполнотой собираемых эксплуатационных данных [8, 9]. В реальных производственных базах данных автосервисов значительная часть технологических параметров фиксируется нерегулярно или вовсе отсутствует. Попытки механического исключения неполных записей из анализа приводят к потере до трети накопленного производственного опыта и резкому смещению обучающих выборок [10]. В свою очередь, наивные методы заполнения пропусков (например, подстановка констант или средних арифметических величин) искажают физические взаимосвязи между признаками и снижают точность итоговых прогнозов.

Настоящая работа посвящена исследованию реального массива данных официальной сервисной сети автопроизводителя, содержащего 50 000 заказ-нарядов. В статье раскрываются производственные причины появления пропусков данных, исследуются методы их корректного заполнения и разрабатывается инженерная модель прогнозирования длительности ремонта, ориентированная на практическое применение в дилерских центрах.

Описание данных и производственная специфика пропусков

Информационную основу исследования составил массив данных сервисного учета официальной дилерской сети крупного автопроизводителя за один квартал. Массив включает ровно $N = 50\,000$ подтвержденных заказ-нарядов.

Каждая запись содержит набор эксплуатационных и технологических параметров, регистрируемых в дилерской информационной системе при оформлении заявки и последующем выполнении работ. Структура признаков приведена в табл. 1.

Таблица 1

Структура параметров сервисного учета дилерской сети

Наименование параметра	Тип данных	Диапазон / Значения	Содержательный производственный смысл
тип_двигателя	Категориальный	Бензин (1), Дизель (2), Газ (3)	Конструктивный тип силовой установки
категория_дефекта	Категориальный	Двигатель (1), Трансмиссия (2), Электрика (3), Кузов (4)	Локализация неисправности и направление цеха
возраст_мес	Непрерывный	1...120 месяцев	Срок фактической эксплуатации автомобиля
пробег_км	Непрерывный	1 000...350 000 км	Эксплуатационная наработка автомобиля
наличие_гарантии	Бинарный	Нет (0), Да (1)	Признак ремонта по заводской гарантии
квалификация_мастера	Порядковый	2, 3, 4 разряд	Уровень квалификации исполнителя по наряду
время_диагностики_мин	Непрерывный	10,0...180,0 мин (пропуски 26,4%)	Длительность инструментального поиска причин
время_ремонта_час	Непрерывный	2,2...12,0 часов	Целевой показатель: фактическая трудоемкость

Для интеграции текстовых категориальных переменных в вычислительные модели выполнено их однозначное кодирование по нормативным словарям дилерской сети (табл. 1). Целевой переменной выступает фактическая длительность ремонта (время_ремонта_час), определяющая время нахождения автомобиля на рабочем посту сервисного цеха.

Природа и механизм возникновения пропущенных значений

Первичный аудит производственного массива показал, что по 7 признакам из 8 пропуски полностью отсутствуют. Единственным признаком, содержащим пропущенные значения, является время_диагностики_мин. В данном столбце пропущено ровно 13 210 записей, что составляет 26,42% (около четверти) от всего объема выборки.

Для инженера критически важно понимать, что пропуски в технологических данных практически никогда не возникают случайно. Анализ распределения пропусков в разрезе категорий дефектов (рис. 1) позволил вскрыть четкую производственную закономерность.

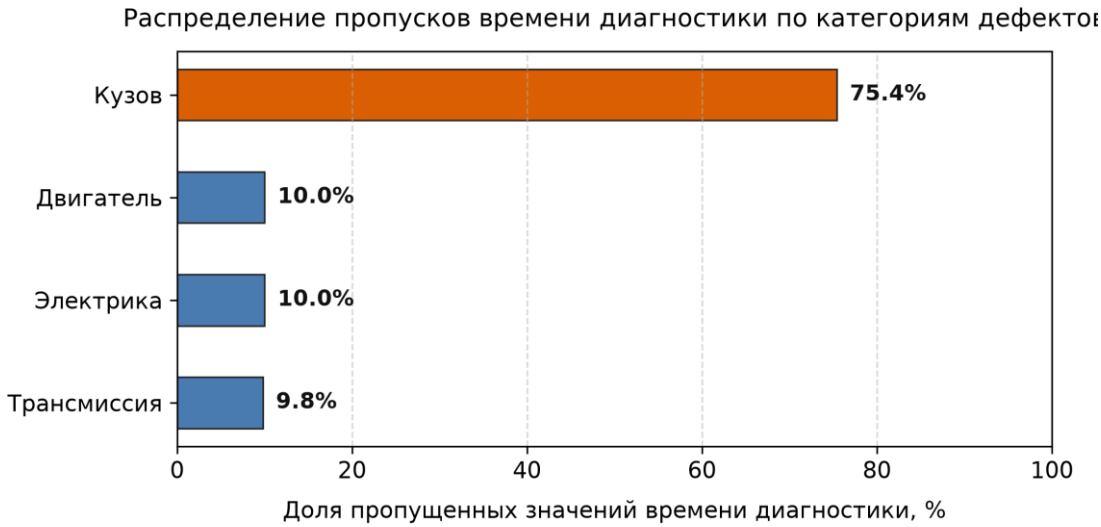


Рис. 1. Доля пропущенных значений времени предварительной диагностики по направлениям сервисного ремонта (общий массив N = 50 000 заказ-нарядов)

Показано распределение пропущенных записей времени приборной диагностики по направлениям ремонта. В категориях агрегатного ремонта доля пропусков составляет около 10%, тогда как при кузовных дефектах достигает 75,4% вследствие отсутствия стендовой инструментальной диагностики в стандартном технологическом регламенте кузовного цеха.

Как видно из рис. 1, по направлениям «Трансмиссия», «Электрика» и «Двигатель» доля незаполненных значений времени диагностики находится на стабильно низком уровне — около 9,8...10,0% (соответственно 999 из 10 039; 1 228 из 12 511; 1 489 из 14 861 заказ-наряда). Эти редкие пропуски вызваны типовыми экспресс-обращениями (например, очевидный обрыв приводного ремня или разрушение патрубка, когда дефект визуально очевиден сразу при осмотре).

Принципиально иная картина наблюдается в категории «Кузов»: здесь доля пропусков достигает 75,42% (9 494 пропущенных значения из 12 589 обращений). Бизнес-причина данной аномалии носит сугубо технологический характер. При кузовных повреждениях (вмятины, сколы, царапины, повреждения ЛКП) мастер-приемщик оценивает характер повреждений визуально («на глаз»), без применения мотор-тестеров, диагностических стендов или считывателей кодов неисправностей. В технологическом регламенте кузовного цеха этап приборной инструментальной диагностики отсутствует как таковой, поэтому соответствующая графа заказ-наряда остается незаполненной.

В статистической теории неполных данных такой механизм классифицируется как MNAR (Missing Not At Random — неслучайные пропуски) [11, 12]. Вероятность отсутствия значения напрямую зависит от содержания других технологических параметров (в данном случае — от категории неисправности). Если инженер пытается заполнить подобные пропуски глобальным средним арифметическим значением (~62 минуты), кузовным дефектам искусственно приписывается часовая приборная диагностика, которой в действительности не проводилось. Это искажает физический профиль ремонтных операций и неизбежно ухудшает точность прогноза.

Заполнение пропущенных значений

Для восстановления целостности технологического массива данных исследованы два альтернативных подхода к заполнению пропущенных значений. Принципиальная схема эксперимента представлена на рис. 2.



Рис. 2. Принципиальная инженерная схема проведения сравнительного эксперимента по заполнению неполных сервисных данных и оценке точности прогнозирования

Отражена общая последовательность этапов исследования: предварительное разделение выборки на обучение и контроль, параллельная реализация способов заполнения пропусков и финальная оценка точности основной модели.

Предотвращение информационной утечки данных

Перед выполнением любых преобразований исходный массив N = 50 000 наблюдений был разделен на две независимые части:

– обучающую выборку (ntrain = 40 000 нарядов, 80%), используемую для настройки всех статистических параметров и моделей;

– контрольную (тестовую) выборку (ntest = 10 000 нарядов, 20%), имитирующую поток вновь поступающих на СТО автомобилей и используемую исключительно для беспристрастной проверки точности.

В прикладном анализе данных строгим правилом является недопущение утечки данных (Data Leakage) [13]. Любые расчетные величины (включая средние значения и коэффициенты вспомогательных уравнений) должны вычисляться исключительно по обучающей выборке. Контрольная выборка обрабатывается на основе уже вычисленных нормативов без «подглядывания» в тестовые строки.

Кроме того, при заполнении времени диагностики категорически запрещено использовать целевую переменную — время_ремонта_час. В момент визита клиента в дилерский центр фактическая длительность ремонта еще неизвестна (именно ее требуется предсказать). Использование времени ремонта при заполнении промежуточных признаков

эквивалентно использованию готового ответа при формулировании вопроса, что лишает методику практического смысла в условиях реального сервиса.

Способ А: Заполнение глобальным средним значением

В рамках первого, наиболее простого подхода по всем строкам обучающей выборки, где инструментальная диагностика была зафиксирована, рассчитывается единое среднее арифметическое значение:

$$t_diag_mean = (1 / m_train) * \Sigma\, t_diag_i \approx 62{,}3 \text{ мин} \quad (1)$$

где m_train — число полных записей в обучающей выборке; t_diag_i — время диагностики i-го автомобиля.

Затем все имеющиеся пропуски (как в обучающей, так и в контрольной выборке) заменяются фиксированной константой t_diag_mean. Преимущество данного способа заключается в предельной вычислительной простоте. Однако его фундаментальный недостаток — игнорирование различий между технологическими группами: и сложная переборка автоматической коробки передач, и локальная покраска бампера получают одинаковое фиктивное время диагностики в 62 минуты.

Способ Б: Регрессионное заполнение (регрессионная импутация)

Второй подход основан на построении вспомогательной прогностической зависимости. Из обучающей выборки отбираются только те строки, в которых время диагностики измерено и зафиксировано в информационной системе. На этих данных строится линейная модель связи времени диагностики с остальными шестью известными характеристиками автомобиля (тип двигателя, категория дефекта, возраст, пробег, статус гарантии, квалификация мастера):

$$t_diag_pred = \beta_0 + \Sigma\, \beta_j * X_j \quad (2)$$

Полученная модель позволяет сформировать индивидуализированный прогноз времени диагностики для каждого незаполненного наряда с учетом его специфики. Для кузовных работ модель автоматически присваивает скорректированные пониженные оценки, а для сложных агрегатных дефектов старых автомобилей с большими пробегами — адекватно увеличенные расчетные интервалы. Спрогнозированные значения подставляются на место пропусков, полностью восстанавливая многомерную структуру матрицы наблюдений.

Построение прогностической модели длительности ремонта

После заполнения пропусков способами А и Б на подготовленных обучающих выборках настраивалась основная модель прогнозирования длительности ремонта автомобиля.

Обоснование выбора линейной регрессии

В качестве базового математического аппарата была принята многофакторная линейная регрессия:

$$y_pred = w_0 + \Sigma\, w_k * X_k \quad (3)$$

где y_pred — прогнозируемая длительность ремонта в часах; X_1, ..., X_7 — совокупность характеристик автомобиля, условий эксплуатации и времени диагностики; w_0, ..., w_7 — искомые весовые коэффициенты модели.

Выбор линейной регрессии вместо сложных нелинейных ансамблей («черных ящиков», таких как глубокие нейронные сети или бустинг) обусловлен тремя принципиальными инженерными соображениями:

1. Чистота экспериментального сравнения: задача исследования состоит в изолированной оценке влияния метода заполнения пропусков на качество итогового прогноза. Линейная модель выступает надежным, прозрачным и строго контролируемым инструментом, свободным от побочных эффектов переобучения [14].

2. Инженерная интерпретируемость: каждый весовой коэффициент w_k имеет прямой физический смысл — он показывает, на сколько часов изменяется длительность ремонта при увеличении соответствующего фактора на единицу (например, рост пробега на каждые 10 000 км или увеличение разряда мастера).

3. Легкость интеграции в сервисное ПО: линейное уравнение легко переносится в любую дилерскую систему (1С, ERP, CRM) без необходимости развертывания специализированных вычислительных библиотек.

Критерии оценки и принцип повторного разбиения выборки

Для оценки качества прогнозирования использовались стандартные инженерные метрики: коэффициент детерминации (R^2), средняя абсолютная ошибка (MAE) и среднеквадратическая ошибка (RMSE):

$$MAE = (1 / n_test) * \Sigma |y_i - y_pred_i| \quad (4)$$

В инженерной практике часто ограничиваются единственным случайным разделением данных на обучение и тест. Однако такое одиночное испытание методологически ненадежно: итоговый результат может случайно оказаться завышенным или заниженным из-за удачного попадания конкретных наблюдений в тестовую группу. Для исключения эффекта случайности в настоящей работе реализована процедура 100-кратного повторного случайного разбиения выборки с независимой генерацией обучающих и тестовых массивов. Итоговые показатели точности фиксировались в виде средних значений и их стандартных отклонений (Mean ± Std).

Сравнительный анализ результатов

Результаты оценки точности прогнозирования длительности ремонта для двух способов заполнения пропусков представлены в табл. 2 и на рис. 3.

Таблица 2

Сравнительная точность прогнозирования длительности ремонта автомобиля

Показатель точности модели	Одиночный запуск А	Одиночный запуск Б	100 запусков А (Mean ± Std)	100 запусков Б (Mean ± Std)	Эффект перехода к Способу Б
Коэффициент детерминации	0,8974	0,9229	0,8980 ± 0,0013	0,9235 ± 0,0012	+0,0254 (+2,54

Показатель точности модели	Одиночный запуск А	Одиночный запуск Б	100 запусков А (Mean ± Std)	100 запусков Б (Mean ± Std)	Эффект перехода к Способу Б
R^2					п.п.)
Средняя абсолютная ошибка MAE, ч	0,754	0,655	0,758 ± 0,005	0,655 ± 0,004	-0,103 ч (-6,2 мин)
Средняя абсолютная ошибка, мин	~45,2 мин	~39,3 мин	~45,5 мин	~39,3 мин	Снижение погрешности
Среднеквадратическая ошибка RMSE, ч	0,936	0,811	0,939 ± 0,005	0,813 ± 0,005	-0,126 ч (рост устойчивости)

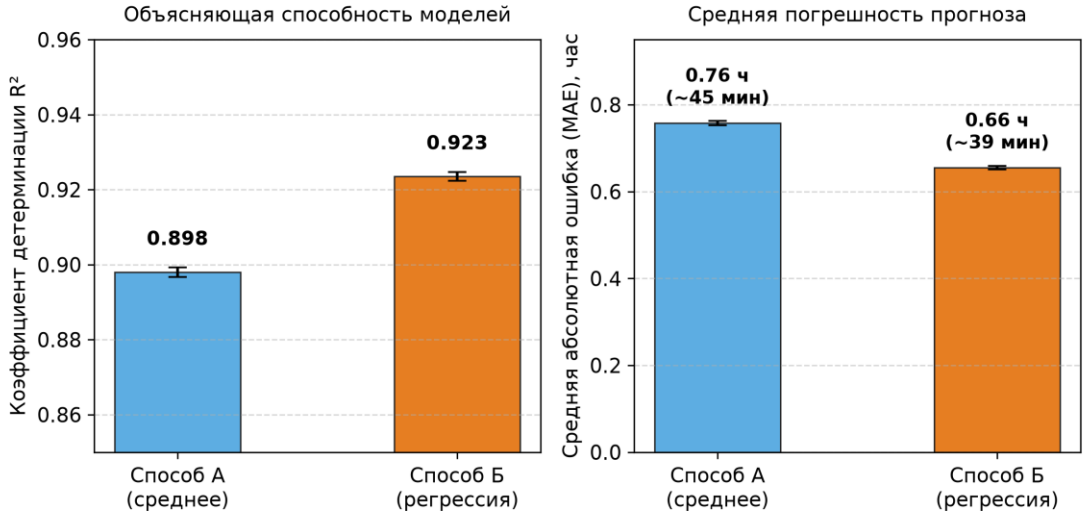


Рис. 3. Сопоставление точности моделей прогнозирования длительности ремонта по результатам 100 циклов валидации: (а) коэффициент детерминации R^2; (б) средняя абсолютная ошибка MAE в часах

Сравнение показателей точности на контрольных выборках. Способ Б демонстрирует статистически устойчивое превосходство: объясняющая способность возрастает до 92,3%, а средняя абсолютная погрешность прогнозирования снижается до 39 минут.

Анализ экспериментальных данных демонстрирует безусловное статистическое и технологическое преимущество регрессионной импутации:

1. Рост объясняющей способности: модель, использующая регрессионное восстановление пропусков, объясняет более 92,3% дисперсии длительности ремонта против 89,8% у модели с подстановкой среднего. Устойчивый прирост составляет +2,54 процентных пункта (ΔR^2 = +0,0254), при этом стандартное отклонение на 100 запусках предельно мало (σ = 0,0012), что свидетельствует о высокой воспроизводимости результатов.

2. Снижение абсолютной погрешности: средняя ошибка прогноза MAE снижается с 0,76 часа (~45,5 минут) до 0,65 часа (~39,3 минут). В масштабах крупного сервисного центра сокращение погрешности на каждые 6 минут в расчете на наряд дает колоссальную суммарную прибавку к точности диспетчеризации.

3. Физико-технологическое объяснение различий: превосходство регрессионной импутации обусловлено не математической сложностью формул, а сохранением предметной

структуры данных. Заполнение пропусков единым числом (62 мин) грубо нарушает технологическую логику: кузовные операции, характеризующиеся объективно меньшей средней трудоемкостью, искусственно «утяжеляются» фиктивной длительной диагностикой. Регрессионная модель учитывает фактор принадлежности к кузовному цеху и подставляет реалистичные оценки, благодаря чему основное уравнение регрессии получает корректно скоординированные исходные данные.

Значение $R^2 = 0{,}923$ означает, что более девяти десятых вариации длительности пребывания машины в цехе удается объяснить доступными параметрами заказ-наряда. Оставшиеся 7,7% разброса приходятся на неконтролируемые случайные факторы: задержку доставки нестандартной запчасти со склада, индивидуальную скорость работы слесаря в конкретную смену или обрыв закисшего крепежа при демонтаже узла.

Практические рекомендации для инженерно-технического персонала сервисной сети

С точки зрения руководства автопроизводителя и инженеров сервисных станций ценность математической модели определяется исключительно тем, какую конкретную пользу она приносит в ежедневных производственных процессах. На основе проведенных исследований сформулирован комплекс прикладных регламентов для персонала официальных СТО.

1. Формат коммуникации с клиентом: уровень точности «до часа»

Одной из типичных ошибок неопытных аналитиков является указание точности прогнозов с точностью до минут или секунд (например, «ремонт займет 4 часа 27 минут 14 секунд»). Для автомобильного сервиса подобная псевдоточность технологически абсурдна и вызывает раздражение автовладельцев при малейшем отклонении.

Фактическая средняя ошибка разработанной модели составляет MAE $\approx 0{,}65$ часа (~39 минут). Следовательно, достигнутая инженерная точность прогноза составляет примерно один час. В регламент работы мастера-приемщика внедряется следующее правило:

– Расчетное значение модели переводится в понятный клиенту часовой интервал готовности.

– Практическая формулировка для автовладельца: «Ваш автомобиль поступил в работу. Ориентировочное время выдачи — завтра после 14:00 (интервал 14:00–15:00)».

Такая формулировка создает у клиента ощущение высокой технологической культуры сервиса, избавляет от необходимости совершать встречные звонки с вопросом «когда будет готово?» и оставляет цеху технологический люфт в пределах одного часа.

2. Сценарии проактивного управления лояльностью клиентов

Прогнозирование длительности ремонта на этапе оформления заявки позволяет сервисному центру перейти от пассивного ожидания к преактивному сервису:

– Короткий ремонт ($\leq$ 2 часов): клиенту уверенно предлагается провести время в комфортной клиентской зоне с чашкой кофе, зная, что задержки не возникнет.

– Средний ремонт (от 2 до 6 часов): клиенту сообщается точное время возвращения на СТО, а при необходимости предоставляется компенсационная услуга такси до дома или офиса.

– Длительный ремонт (> 6 часов или переход на следующие сутки): если модель при приеме фиксирует длительность свыше 6–8 часов, дилерский центр заблаговременно (до возникновения недовольства) предлагает автовладельцу услугу подменного автомобиля (courtesy car) либо выдает сертификат на бесплатную мойку или следующее плановое ТО. Заблаговременное предоставление подменного транспорта трансформирует потенциальный конфликт в фактор наивысшей клиентской лояльности.

3. Диспетчеризация сервисных постов и управление трудоемкостью

Для мастера цеха и инженера-диспетчера внедрение модели обеспечивает:

– Динамическое распределение постов: автоматизированный расчет длительности позволяет планировать расстановку автомобилей на подъемниках без образования заторов на выкатных путях;

– Балансировку квалификации мастеров: наряды с высокой прогнозируемой трудоемкостью автоматически назначаются на специалистов 4-го разряда, тогда как регламентные операции с короткой длительностью направляются слесарям 2-го и 3-го разрядов;

– Контроль скрытых отклонений: если фактическое нахождение автомобиля на посту превышает прогноз модели более чем на 1,5 часа, система подает тревожный сигнал мастеру смены для оперативного выяснения причин (нехватка инструмента, поломка крепежа, ожидание деталей со склада).

Заключение

Выполненное исследование позволяет сформулировать следующие основные научные и практические результаты:

1. Обоснована производственная актуальность предиктивного моделирования сервисных процессов: показано, что внедрение аналитических моделей длительности ремонта позволяет устранить информационный разрыв между приемкой и ремонтным цехом, сформировав основу для ритмичного планирования постов и доверительных отношений с клиентами.

2. Раскрыта технологическая природа пропусков данных в сервисной сети: на массиве из 50 000 заказ-нарядов установлено, что 26,4% пропусков времени диагностики носят неслучайный характер (MNAR). В кузовном цехе доля пропусков достигает 75,4% вследствие отсутствия стендовой приборной диагностики в регламенте кузовных работ.

3. Доказана эффективность регрессионной импутации: сравнительный анализ на базе 100 циклов независимого разбиения выборки подтвердил, что регрессионное заполнение пропусков превосходит традиционную подстановку среднего, обеспечивая прирост объясняющей способности с $R^2 = 0{,}898$ до $R^2 = 0{,}923$ (+2,54 п.п.) и снижение средней погрешности MAE до 0,65 часа (39 минут).

4. Выявлен физический механизм превосходства метода: в условиях структурной зависимости пропусков от категории дефекта подстановка глобального среднего искажает

профиль трудоемкости кузовного ремонта, тогда как регрессионное заполнение корректно восстанавливает межкатегориальные технологические связи.

5. Сформированы практические регламенты для инженерных служб: обоснован дискретный формат клиентских обязательств с точностью «до часа» (регламент «Приезжайте завтра после 14:00»), разработаны критерии превентивного предоставления подменного автотранспорта и алгоритмы сбалансированной загрузки сервисных постов по квалификации мастеров.

Список литературы

1. ГОСТ Р ИСО 9001-2015. Системы менеджмента качества. Требования. — М. : Стандартинформ, 2015. — 32 с.
2. ГОСТ 18322-2016. Система технического обслуживания и ремонта техники. Термины и определения. — М. : Стандартинформ, 2017. — 15 с.
3. Козловский В.Н., Строганов В.И., Клентак А.С. Комплекс методов предиктивного анализа надежности и качества автомобильной техники // Автомобильная промышленность. — 2020. — № 8. — С. 14–20.
4. Панюков Д.И., Козловский В.Н. Системы предиктивного управления качеством высокотехнологичной продукции в концепции Индустрии 4.0 // Известия Самарского научного центра Российской академии наук. — 2021. — Т. 23, № 4(102). — С. 45–54.
5. Шарапов С.А., Козловский В.Н. Методика многофакторного анализа гарантийной дефектности легковых автомобилей // Вестник машиностроения. — 2019. — № 6. — С. 78–83.
6. Кутин А.А., Григорьев С.Н. Организация и управление сложным машиностроительным производством на основе CALS-технологий // Известия Самарского научного центра РАН. — 2012. — Т. 14, № 4(2). — С. 412–417.
7. Савич Е.К. Методология создания и функционирования интеллектуальной цифровой системы менеджмента качества : дис. … канд. техн. наук : 2.5.22. — Самара : СамГТУ, 2025. — 178 с.
8. Антипова О.И., Горохова Д.А. Подходы к цифровизации систем менеджмента качества // Вестник Южно-Уральского государственного университета. Серия: Компьютерные технологии, управление, радиоэлектроника. — 2022. — Т. 22, № 3. — С. 45–56.
9. Попов М.А. Развитие машиностроительного предприятия на основе цифровизации интегрированной системы менеджмента // Наука и реальность. — 2023. — № 2. — С. 78–85.
10. Little R.J.A., Rubin D.B. Statistical Analysis with Missing Data. — 3rd ed. — Hoboken, NJ : John Wiley & Sons, 2019. — 462 p.
11. Rubin D.B. Inference and missing data // Biometrika. — 1976. — Vol. 63, № 3. — P. 581–592.
12. Van Buuren S. Flexible Imputation of Missing Data. — 2nd ed. — Boca Raton, FL : CRC Press, 2018. — 434 p.
13. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. — 2nd ed. — New York : Springer, 2009. — 745 p.
14. Montgomery D.C., Peck E.A., Vining G.G. Introduction to Linear Regression Analysis. — 5th ed. — Hoboken, NJ : John Wiley & Sons, 2012. — 672 p.
15. Lee J., Bagheri B., Kao H.-A. A Cyber-Physical Systems architecture for Industry 4.0-based manufacturing systems // Manufacturing Letters. — 2015. — Vol. 3. — P. 18–23.

16. Wuest T., Weimer D., Irgens C., Thoben K.-D. Machine learning in manufacturing: advantages, challenges, and applications // Production & Manufacturing Research. — 2016. — Vol. 4, № 1. — P. 23–45.

Фрелих Иван Павлович, аспирант кафедры «Управление качеством и стандартизация», ivan.frelikh@yandex.ru, Россия, Самара, Самарский государственный технический университет.
Мосин Владимир Геннадьевич, доктор технических наук, кандидат физико-математических наук, доцент кафедры «Высшая математика», yanbacha@yandex.ru, Россия, Самара, Самарский государственный технический университет.

PREDICTING VEHICLE REPAIR DURATION IN AN AUTOMAKER'S SERVICE NETWORK UNDER INCOMPLETE DATA CONDITIONS

I.P. Frelikh, V.G. Mosin

The paper addresses the operational problem of predicting the duration of maintenance and repair operations across an automotive dealership network. Accurate scheduling of service bays and providing vehicle owners with realistic turnaround times represent pivotal factors in sustaining customer loyalty and enhancing dealership profitability. An industrial dataset comprising 50,000 warranty and post-warranty work orders from an official dealership center is analyzed under conditions of severe data incompleteness: 26.4% of records lack diagnostic duration records. It is shown that the missingness mechanism is missing not at random (MNAR), directly stemming from shop-floor practices: bodywork repairs are assessed visually without instrumented test benches, resulting in a 75.4% missingness rate, whereas powertrain and electrical defect categories exhibit missingness below 10.0%. Two data imputation approaches are benchmarked: conventional mean imputation and multivariate regression imputation that reconstructs latent relationships between vehicle characteristics and diagnostic labor. To eliminate single-split volatility, models were validated across 100 independent random train/test iterations (80/20 split). Regression imputation consistently increases the determination coefficient from $R^2 = 0.898$ to $R^2 = 0.923$ (+2.54 percentage points) and reduces mean absolute error (MAE) from 0.76 h (45 minutes) to 0.65 h (39 minutes). From an applied engineering perspective, the resulting model accuracy enables dealership service desks to state customer delivery commitments with single-hour precision (actionable communication guideline: "Vehicle ready tomorrow after 2:00 PM") and proactively deploy compensatory customer service scenarios (courtesy vehicles or service vouchers) whenever long-duration repairs are anticipated.

Keywords: vehicle maintenance and repair, dealership service network, repair duration prediction, incomplete data, missing not at random, data imputation, regression model, customer service management, service bay scheduling, quality management system.

Frelikh Ivan Pavlovich, Postgraduate Student, Department of "Quality Management and Standardization", ivan.frelikh@yandex.ru, Russia, Samara, Samara State Technical University.
Mosin Vladimir Gennadievich, Doctor of Technical Sciences, Candidate of Physical and Mathematical Sciences, Associate Professor, Department of "Higher Mathematics", yanbacha@yandex.ru, Russia, Samara, Samara State Technical University.